Assignment 3
Code optimization and reporting

Mads Wulff Nielsen
Claus Kramath

21. april 2021

Indhold

1 Introduktion

Programmet, vi vil forsøge at optimere, beregner frekvensen af forekomsten af et bogstav i en tekst. Programmet er klonet fra flg. github repository:

1. `https://github.com/CPHBusinessSoftUFO/letterfrequencies`

Det oprindelige program indlæser en tekstfil, gennemløber karaktererne i denne enkeltvis og akkumulerer antallet af hver karakters forekomster løbende i et HashMap. Til sidst udskrives antallet af hver karakters forekomst; frekvensen.

2 Instruktion

Herunder er instruktioner til at køre den optimerede kode på egen maskine:

1. Vores optimerede løsning kan downloades her:
   `https://github.com/CK2800/UFO/tree/master/3`
2. Åbn projektet i IntelliJ eller tilsvarende IDE.
3. Kør Main.main() fra IDE'et, bemærk at der køres 500 loops. Vores benchmark indikerer, at det bør tage ca. 75 sek. på en i5, 2.2 GHz.
4. Observer mean og standard deviation udregningerne i konsollen. Disse udregnes for hvert 50. loop.
5. Kør nu Main i kommandoprompten ved at navigere til /target/classes og skrive flg. kommando:

   ```
   java cphbusiness.ufo.letterfrequencies.Main
   ```

6. Observer igen mean og standard deviation værdierne i konsollen.

3 Fremgangsmåde

For at identificere flaskehalse i programmet, har vi brugt Java flight recorder profileren, som findes i vores IDE; IntelliJ. Af billedet herunder fremgår det, at kørslen af programmet i sin helhed især bruger tid på

```
Main.tallyChars(Reader, Map)
```

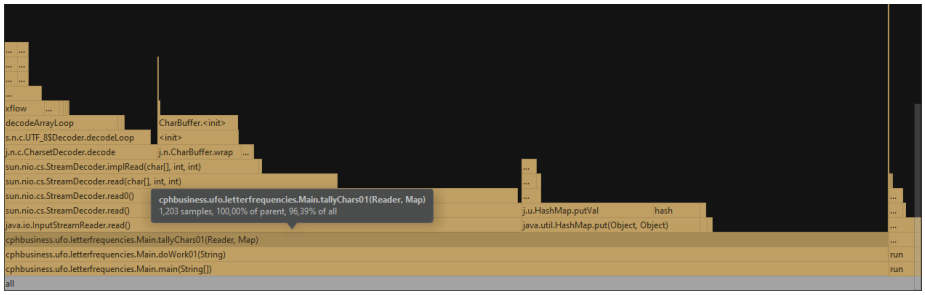

Figur 1: Flammegraf for original tallyChars metode.

Billedet med flammegrafen viser også, at der er relativt mange skridt forbundet med den originale kode. Eksempelvis kaldes der ofte metoder på StreamDecoder- og CharsetDecoder-objekter, før karakteren indsættes i HashMap. Med identifikationen af den mulige flaskehals, granskede vi den originale kode for at forstå den, samt fremkomme med umiddelbare optimeringsskridt.

```
/**
 * Reads bytes from the file one at a time and increments occurences in a hashmap.
 * @param reader
 * @param freq
 * @throws IOException
 */
private static void tallyChars01(Reader reader, Map<Integer, Long> freq) throws IOException {
    int b;
    while ((b = reader.read()) != -1) {
        try {
            freq.put(b, freq.get(b) + 1);
        } catch (NullPointerException np) {
            freq.put(b, 1L);
        };
    }
}
```

Figur 2: Original tallyChars metode.

Vores umiddelbare mistanke faldt på det faktum, at koden traverserer hele filen, 1 bogstav ad gangen. Dette resulterer i mange læsninger på disken, hvorfor vi drøftede følgende løsningsforslag:

1. Indlæsning af (dele af) filen til RAM.
2. Anvendelse af alternativ reader, eventuelt med indbygget buffer.
3. Læse filen i større bidder ved brug af byte arrays.

3.1 Fravalg af forslag 1

Vi indså hurtigt at indlæsning af filen inden kørslen af Main.tallyChars ville bryde med kontrakten, idet en ændring af indlæsningstidspunkt for filen vil medføre, at indlæsningsmetoden skal køres først. Dette vil medføre ændringer i kodebasen andre steder, idet en ny metode til indlæsning af filen i RAM ville skulle kaldes først.

3.2 Anvendelse af alternativ reader

Med vores mistanke om flaskehalsens årsag in mente, tog vi en BufferedInputStream i brug, for at teste, om læsning af buffer fra memory ville gøre nogen forskel. Som det kan ses af flg. graf, var det en forbedring i kørselstiderne. Brugen af BufferedInputStream er imidlertid også et brud på kontrakten, idet der fordres en ny signatur på metoden:

```
private static void tallyChars(BufferedInputStream stream,
    Map<Integer, Long> freq)
```

Anvendelsen af BufferedInputStream skal således ses som en afprøvning af konceptet med en buffer at læse fra. Senere kunne vi formentlig have brugt BufferedReader for overholdelse af kontrakten;

```
private static void tallyChars(Reader reader, Map<Integer,
    Long> freq)
```

Som det fremgår af figurerne 3 - 6, er indlæsning i større bidder en plausibel løsning, idet den blå kasse med hale viser den originale tallyChars-metode. Den grå kasse med hale viser tider med indlæsning vha. BufferedInputStream:

3.3 Indlæsningstider

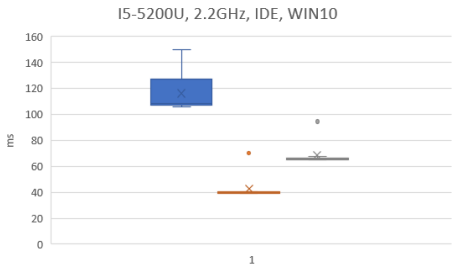

Figur 3: Kørselstider, IDE, Win10.

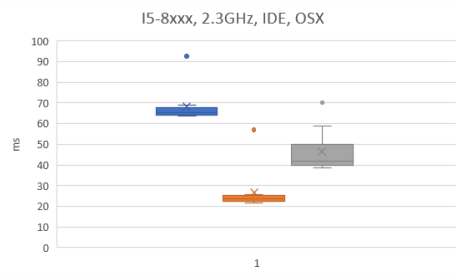

Figur 4: Kørselstider, IDE, OSX.

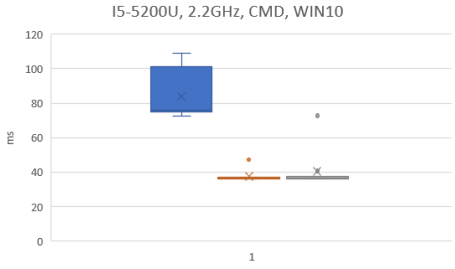

Figur 5: Kørselstider, CMD, Win10.

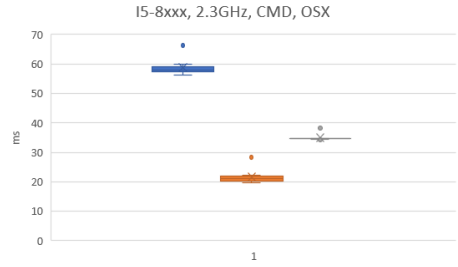

Figur 6: Kørselstider, CMD, OSX.

3.4 Indlæsning af filen i bidder vha. char array

Som det videre fremgår af figurerne 3-6 ovenfor, er indlæsning vha. et char-array en hurtig løsning. Den orange kasse med hale er, i alle 4 figurer, den hurtigste og har samtidig ganske stabile kørselstider, uanset om den afvikles fra ide eller kommandoprompt. Vi har forsøgt at justere på længden af char-array'et, den bedste performance opnås dog ved enten 128 eller 256 pladser. Vores tese er, at det lagrede array, ved mange elementer, fylder mere end der er plads til i RAM, derfor skrives dele af array'et måske til disken.

4 Videre optimering

Vores optimerede kodes hurtigere kørselstid kan også ses af nedenstående flammegraf, der viser en markant mindre dybde i nestede kald fra tallyChars-metoden.

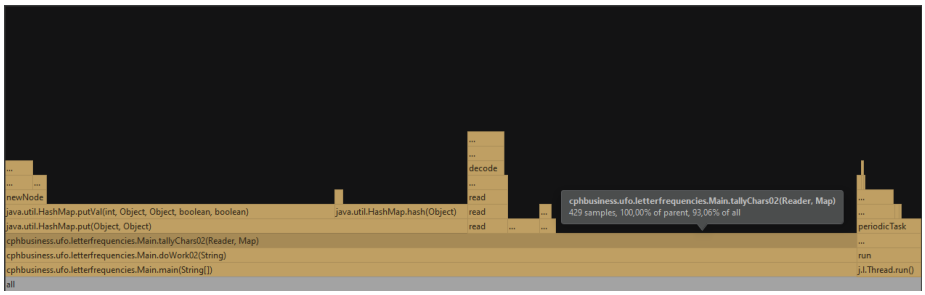

Figur 7: Flammegraf med færre nestede kald fra tallyChars.

Koden er således klar til videre forædling. Vi opstiller her et par forslag som vil give yderligere forbedringer i kørselstiderne.

1. Fjernelse af try-catch sætningen og istedet returnerer getOrDefault.
2. Tråde til at indlæse parallelt.
3. Alternativ datastruktur til HashMap.

```
/**
 * Reads bytes from the file in chunks of 256 bytes and increments occurences in a hashmap.
 * @param reader
 * @param freq
 * @throws IOException
 */
private static void tallyChars02(Reader reader, Map<Integer, Long> freq) throws IOException {
    char[] chars = new char[256];
    while((reader.read(chars)) != -1){
        for(char b : chars)
            try {
                freq.put((int)b, freq.get((int)b) + 1);
            } catch (NullPointerException np) {
                freq.put((int)b, 1L);
            };
    }

}
```

Figur 8: Optimeret tallyChars metode.